

第一篇（XIPHOS：车内入侵检测）：这篇是做车载 CAN/IVN 入侵检测的，背景是车越来越联网，CAN 总线又天生没认证没加密，插点东西进去就能注入/伪造报文，安全威胁和人身安全直接挂钩。

作者吐槽现有深度学习 IDS 的几个痛点：很多方法还是把 CAN 当普通多维时序来做，挖不出 CAN ID 之间那种“拓扑/耦合”规律；监督方法太吃标签，而且真实世界里攻击样本少、标注贵、分布还不平衡；纯无监督方法又经常不稳定、容易受噪声影响；另外很多模型没考虑车端资源受限、实时性和车云协同部署的问题。

他们提出 XIPHOS：核心是“无监督 + 图对比学习 + 还能自适应”。第一步先把原始 CAN 流量转成图结构数据（利用车辆通信节点之间的逻辑拓扑和数据流耦合特征），而不是死盯着原始时序矩阵。

然后上图对比学习（Graph Contrastive Learning）：用互信息最大化（MI maximization）的思路去学表征，把局部信息和全局信息一起融合，既能得到图级表示也能得到节点级表示（这点挺关键，等于既能做整体窗口是否异常，也能细到节点/局部异常）。

检测阶段他们不是简单给个阈值完事，而是结合“自编码器重构误差 + 分层聚类/自适应分类”，再用单高斯模型（SGM）去分析最终分类；而且强调“可更新”：在不同场景/不同时间段，可以用一部分正常样本重新启动训练/更新参数，适应数据漂移。

实验是在两个常用 CAN 注入攻击数据集上（一个更偏仿真环境，一个包含真实车辆攻击），结果说在不依赖攻击标签的前提下，检测性能比现有方法更好，而且更适合车端资源受限 + 车云协同的落地形态。结论里也强调：不需要先验攻击模式，能动态适应未知威胁，这就是它想卖的点。

第二篇（ScaleOT：离线/异地微调的隐私-效用折中）：这篇是讲 offsite-tuning 的，也就是模型方不想把完整 LLM 权重给出去（怕泄露/被攻击/被盗用），数据方也不想把数据上传（隐私），于是模型方提供一个“有损压缩的 emulator”，让数据方在 emulator 上训练 adapter，然后把 adapter 交回模型方去 plug-in 到原模型上得到效果。

问题是现有 offsite-tuning 常见做法要么是均匀丢层（Uniform LayerDrop）导致适配性能掉得厉害、层间表征对不齐；要么靠知识蒸馏把 emulator 补回来，但蒸馏太贵，尤其大模型根本不好搞；同时压缩强度又直接影响隐私保护强度（压得越狠越不容易反推模型）。

ScaleOT 的核心是“隐私-效用可伸缩”：它先用强化学习估每一层的重要性（importance scores），然后提出 Dynamic LayerReplace：不重要的层不直接丢掉，而是用轻量网络 harmonizer 去替换（相当于做对齐/补偿），重要的原始层保留。最后按不同的比例把“原始重要层 + harmonizer”组合起来，生成不同尺度的 emulator（想更隐私就压更狠，想更好用就保留更多原层）。

此外还有一个 SRC（Selective Rank Compression）：对保留下来的原始层再做选择性低秩压缩（rank reduction），据说能进一步提升隐私，但对 plug-in 性能影响很小（大概就是让

emulator 更弱、更难泄露，但 plug 回去还能保持）。

实验上他们测了 GPT2-XL、OPT-1.3B、OPT-6.7B、LLaMA-7B 等，任务包括 WikiText 的困惑度和一堆 QA 基准（OBQA/PIQA/ARC/HellaSwag/SciQ/WebQuestions/RACE 之类）。结论是：ScaleOT（尤其不用蒸馏）能做到接近 full fine-tuning 的 plug-in 表现（几乎无损），比 OT 的均匀丢层好很多；加 SRC 后 emulator 的表现明显更差一些（隐私更强），但 plug-in 只掉很少；而且他们还说对参数高效微调方法（Adapter/LoRA）是正交的，可以一起用。

最后的 takeaway 就是：通过“按层重要性 + 替换层 + 选择性降秩”，在不搞昂贵蒸馏的情况下，让 offsite-tuning 可以更灵活地调隐私/效用，并且在不同模型规模上都能跑得通。